# 学习如何研究

## AI 科研品味、科学发现与经验学习的问题导向综述

Learning to Do Research

Awesome Autoresearch project

文献快照：2026 年 10 月 26 日
工作综述与待验证的研究议程

**摘要**

AI 系统已经能够提出想法、修改代码、运行实验和撰写研究报告。更难的问题是：它们能否做出更好的科研决策，选择有用的未知问题，设计有信息量的检验，拒绝证据不足的解释，并把经验带到新的项目中？本文按照科研品味、问题形成、可靠执行、经验学习与评价这五个问题，综合 Awesome Autoresearch 集合中的 79 项资源。我们比较不同方法使用的反馈与证据，而不把完成科研流程当作科学能力的单一指标。集合包含 72 篇论文、6 篇文章或演讲以及 1 个软件项目。每个问题章节以局限、开放问题和两项具体实验方向结束，随后给出三个可优先启动的项目及共享评价协议。本文以 AI research 为主要 testbed，数学为补充场景。提出的实验均为研究设计，不是已经获得的结果，也不构成对方法新颖性的确认。

**关键词：**autoresearch；AI for meta-science；科研品味；假设生成；AI scientists；科研 agent 学习。

## 目录

**1 范围：如何改进研究过程** **2**

**2 Q1：如何让 AI 判断什么研究值得做？** **3**

**3 Q2：如何让 AI 提出有用的研究问题？** **5**

**4 Q3：如何把问题转化为可靠知识？** **6**

**5 Q4：研究经验如何改善研究者？** **9**

**6 Q5：如何评价更好的科研？** **12**

**7 可执行的研究议程** **14**

**参考文献** **16**

# 1 范围：如何改进研究过程

本文关心如何构建越来越会做研究的 AI：选择问题，把直觉转成可检验的命题，获得证据，修订判断，并改善后续决策。有用的系统不必自动化每个环节。帮助研究者放弃一次没有信息量的实验，可能比生成一篇完整但薄弱的论文更有价值。

我们用 *autoresearch* 指这一广义方法方向，其中包括人机协作和自主系统。*Meta-science* 研究科学如何运行，以及如何改进科学实践。机器学习中较窄意义的 *meta-learning*，则是跨任务学习科研策略的一条技术路线，并不是所有收录方法都必须采用的机制。本文以研究过程为对象，以 AI research 为主要实验场景。数学提供补充 testbed，因为其中很多候选答案、程序和构造可以被精确检查。可检查性有助于评价，但不能决定问题本身是否重要。

## 1.1 五个问题与两个时间尺度

Q1 讨论哪些问题值得投入，Q2 讨论怎样形成能通过研究解决的问题，Q3 讨论系统能否产生支持结论的证据，Q4 讨论经验究竟改变了研究者的什么，Q5 则讨论如何分别测量这些能力。完整 AI scientist systems 放在 Q3 中讨论，因为它们展示了各环节如何相互影响。

这里存在两个不同的时间尺度。在一个项目内部，agent 可以改进候选解、修订实验或切换搜索分支。在不同项目之间，它可以保留报告、积累技能、修改控制代码或更新模型权重。评价后一类改善时，可以采用下面的概念性比较：

$$\Delta_{\text{transfer}} = S(\pi_{\text{after}}; \mathcal{T}_{\text{new}}, B) - S(\pi_{\text{before}}; \mathcal{T}_{\text{new}}, B), \tag{1}$$

其中 $\mathcal{T}_{\text{new}}$ 包含留出的任务家族，$B$ 为相同的评价预算，$S$ 是事先声明的结果指标。这是本文建议的比较方式，不是科学进步的通用定义；获取经验本身的成本也需要报告。在适应所用的同一任务上获得更好结果，不能估计这一迁移量。

## 1.2 什么是好的研究问题？

问题可能新颖却不重要，重要却暂时无法检验，也可能容易执行但已经有答案。因此我们分别讨论五个判断：解决未知的**重要性**，相对于相关工作的**新颖性**，命题的**可检验性**，给定预算下的**可行性**，以及包括负结果在内的**信息价值**。它们是本文的分析维度，并非已经验证的评分量表；各维度的权重取决于领域和研究目的。

例如，“提高这个分类器的准确率”给出了优化目标。“一种新 augmentation 的收益来自不变性，还是仅仅来自更多训练更新？”则识别了相互竞争的解释。后者自然引出 matched-compute control，即使新方法没有增益，也可能产生有用知识。这个例子用于说明区别，不表示该 augmentation 问题具有新颖性。实际挑战在于让 agent 根据真实文献和可获得证据，提出这样的区分。

研究者的文章能帮助描述目前 benchmarks 只测到一部分的判断力。Olah 提出用低成本、带噪声的反馈训练 taste；Karpathy 讨论项目选择与推进；Hamming 强调重要问题的选择 [1–3]。Nielsen 强调好问题经常需要在工作中被发现，*Research Debt* 则说明更好的抽象与解释也可以成为研究贡献 [4, 5]。Nielsen 与 Qiu 进一步把科学判断放在注意力和资源分配制度中讨论 [6]。这些观点可以启发 AI 研究假设，但不是已经证明能训练有效 agent 的实验证据。

## 1.3 文献范围与综合方式

本文是基于固定仓库快照的批判性叙述综述，并不声称完成了穷尽性的 systematic review。快照包含 72 篇论文、6 篇文章或演讲，以及 Karpathy 的 autoresearch 软件项目。表 1 按仓库中的主要贡献分类计数。79 项资源全部进入讨论与参考文献；有些用于背景理解，而非作为核心实证证据。配套源码保存条目标识、主要来源链接、核查日期和引用到章节的覆盖关系。

比较方法时，我们关注 agent 负责哪些决策、人类提供哪些输入、系统使用什么反馈，以及研究如何评价成功。关键方法论描述通过原始论文或官方材料核对。来源核查不等于独立实验复现。不同 backbone、预算、任务版本和评审协议下的 headline scores 不直接汇总成排行榜。每个问题章节末尾的方案是本文提出的研究设计，其中样本数和资源上限属于建议的 pilot 设置，不是统计功效计算或已经证明最优的配置。正式声称方法新颖性之前，仍需围绕具体方案补做检索。

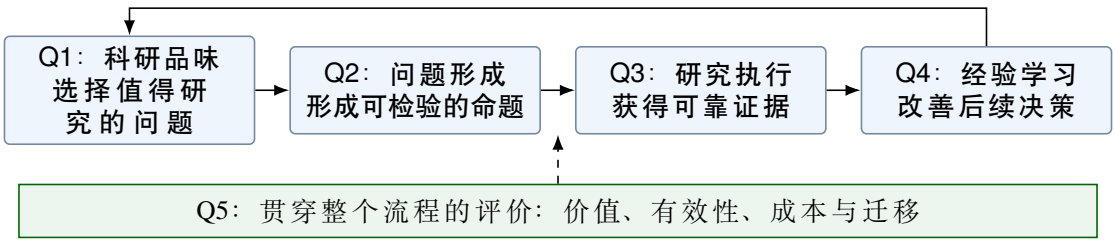



**图 1:** 本文的研究地图。反馈既可以修订当前项目，也可以改变后续项目的研究方式。顺序用于组织讨论，不是固定工作流。

**表 1:** 按仓库主类别统计的文献集合。类别在概念上可以重叠，每项资源只计数一次。

| 类别 | 数量 | 类别 | 数量 |
|---|---|---|---|
| 科研品味 | 8 | 问题形成 | 14 |
| 研究执行 | 11 | 经验学习 | 18 |
| 评价 | 16 | 完整系统 | 6 |
| 文章与演讲 | 6 | 总计 | 79 |

## 2 Q1：如何让 AI 判断什么研究值得做？

Research taste 关心的是结果尚未确定时的决策：哪些未知值得研究，哪些提案值得投入资源，以及什么结果应该改变下一步实验。因此，评价必须说明决策情境。对已完成论文排序、筛选未执行提案和选择下一个实验彼此相关，但可见信息与反馈不同。本文将新颖性、可行性、预期信息增益和资源需求分开讨论，不预设某个单一分数就能表示 scientific value。

### 2.1 不同反馈究竟测量了什么

AI Can Learn Scientific Taste 将学术共同体的反响转化为训练信号：在同领域、同年份论文中依据引用差异构造偏好，训练 Scientific Judge，再用它奖励 Scientific Thinker。作者、机构和主题控制排除了一部分明显的捷径。不过，生成器仍通过 LLM 对潜在影响力的比较进行评价，并未执行提案 [7]。这支持偏好能够被学习并传递到生成端，但尚未确认这种偏好与实际科研价值的关系。

HindSight 的目标不同：将生成想法与后续论文匹配，再利用发表相关的影响信号加权。它使回顾式比较成为可能，却也奖励与后来已发表研究的一致性；没有后续匹配的方向未必没有价值。更关键的是，文中模型知识截止时间晚于检索截止时间，仅限制检索文献不能排除模型知道评价窗口中的内容 [8]。因此，本文将其视为 retrospective alignment 的证据，而非严格的 prospective discovery forecast。

TasteVal 从论文偏好转向实验决策：给定研究问题，固定 coding agent，衡量实验算力与研究进展的关系。这有助于区分规划、解释与代码实现，但测量仍依赖 coder、任务、预算和评分规则，而且任务未公开发布 [9]。其结果不能直接证明开放式选题能力，也不能将这一协议当作已可获取的公共训练集。

执行还可能改变评价本身。Ideation–Execution Gap 在研究者选择的主题内随机分配人类或 LLM 提案，再对执行成果进行专家盲审；LLM 提案在最初评价中的优势经实施后减弱 [10]。它比单纯提案评分更接近实际成果，但人类执行和特定 NLP 情境仍是实验条件的一部分。这些研究未必相互矛盾：预判共同体反响、获得评审认可、选择有效实验，本来就是不同的预测目标。

### 2.2 有证据的判断与对捷径的抵抗

一条路线是缩小判断范围并公开依据。RINoBench 对照从专家评审中提取的标签评价新颖性分数和理由；OpenNovelty 将论文贡献主张与相关工作逐项比较；InnoEval 则结合检索证据与多种评审视角 [11–13]。这些方法让判断更容易检查，但仍依赖检索覆盖和比较的可靠性。看似合理的理由可以伴随错误分数；证明主张区别于已有工作，也不能证明它值得研究。

**表 2:** Research taste 的反馈来源及其支持的推断；任何一种目标都不能单独定义科学价值。

| 反馈来源 | 可观察目标 | 尚未解决的问题 |
|---|---|---|
| 共同体反响 [7, 8] | 引用偏好或后续发表匹配 | 未发表的替代方向及因果意义上的科学价值 |
| 专家或证据判断 [11–13] | 新颖性判断与评审一致性 | 证据缺失与评审偏好 |
| 受控扰动 [14] | 对风格稳定、对内容变化敏感 | 稳健性是否预示有效研究 |
| 实际执行 [9, 10] | 预算内进展或执行后评价 | 对实现方式与任务选择的依赖 |

SciStyleBench 提出互补问题：judge 对科学内容敏感，还是对其表达方式敏感？它将风格变化与内容削弱、增强分别干预。关键是同时满足两项要求：不受无关修辞影响，又能识别方法变化；恒定评分器虽满足不变性，却没有判断价值 [14]。本文据此认为，evidence grounding 与 shortcut resistance 应联合评价。增加文献可以补充事实，但不会自动让决策规则忠实于这些事实。

## 2.3 局限与开放问题

现有证据支持多种 taste 的操作化定义，尚未建立统一能力。廉价标签利于扩展，昂贵执行提供更直接但范围更窄的反馈；两者都不能消除评价分歧或替研究者决定目标。如何奖励有信息量的负结果、何时允许 judge 弃权、收益能否跨任务和独立实现保留，仍是开放问题。前瞻研究应在观察结果前冻结提案、评审器、预算和可访问信息。以下方案均为拟议实验，并非已证实的结论。

## 2.4 拟议计划一：结合执行结果与主动标注的提案排序

**研究假设与方法**。在固定标注预算下，结合已完成 pilot 的结果与主动请求的专家偏好，比仅学习执行前评分更能选出可复现、具有信息量的研究。以小型 pairwise judge 为起点，优先请求不确定或存在分歧的样本对，同时保留随机标注比例并记录抽样概率。专家依据预先定义的 rubric 比较训练阶段已执行 pilot，承认有效负结果的价值，并区分实现失败与假设被否定。

**任务与划分**。围绕冻结小模型的校准、检索评分和鲁棒性构造十二个低成本 AI 研究任务，每个包含六项候选干预。六个任务用于训练、三个用于开发、三个用于封存评价；共享数据集和代码模板的任务必须放在同一分区。评价阶段以相同 coder 和预算执行全部候选，使用独立随机种子复现；排序冻结前不开放结果。这个适度规模的设计检验跨任务迁移，不声称测量普遍科研品味。

**对照、指标与风险**。比较随机选择、直接提示 judge、仅提案偏好训练，以及随机标注的执行结果训练；分别消融主动选择与执行反馈。指标包括 top-$k$ 中可复现且有信息量结果的比例、相对全部候选执行结果的 ranking regret、校准、标注成本和实验成本，并报告跨任务不确定性。主要风险是结果噪声、偏爱容易项目，以及主动抽样遗漏陌生想法；随机样本提供审计入口，但不能消除这些风险。

## 2.5 拟议计划二：抵抗捷径但保留内容辨别力的 judge

**研究假设与方法**。将主张、支持证据与表达线索分开，有望提高风格变化下的排序稳定性，同时保留对无效方法的敏感性。围绕约一百个提案构造受控变体：一组改变措辞、确定语气和声望线索；另一组移除必要对照、引入矛盾或缺乏依据的机制。由独立标注者核实干预是否保留或改变目标内容，再用不变性与内容辨别两个目标训练轻量 pairwise evaluator。

**任务、对照与评价**。按原始提案、主题和改写模型划分，确保同一想法的所有变体属于同一分区。比较直接提示、检索增强评价、文本规范化，以及两个训练目标分别单独使用的结果。测量风格导致的分数变化、实质缺陷识别率和对抗表达下的 top-$k$ 更替，并在计划一封存的已执行任务上检验稳健性是否改善选择质量。

**失败风险**。改写可能改变语义，规范化可能删掉有用细节，人工缺陷也可能比真实科研弱点容易识别，因此必须人工审计并保留未经改写的提案。即使通常的 judge agreement 上升，只要风格敏感性下降伴随缺陷辨别或下游选择质量退化，就应判为失败。

# 3 Q2：如何让 AI 提出有用的研究问题？

研究问题说明什么值得弄清，研究提案还说明准备如何弄清。很多系统由人类提供问题或动机，再在这一背景中生成新方法；输出可以有用，但不代表自主发现问题。本文认为，有用的问题应说明尚未解决的主张、区分合理的替代解释，并指出哪些观察会改变答案。这一标准也为有信息量的负结果保留空间，不将科研质量等同于提出能提高 benchmark 分数的方法。

## 3.1 候选问题从哪里来

基于文献的方法主要区别在于如何组织搜索空间。SciMON 从语义、知识图谱和引用邻域获取启发，再对照相关文献修改想法；其输入背景已经给出动机和约束 [15]。ResearchAgent 围绕种子论文及关联知识发展问题、方法和实验计划；SciPIP 结合检索与 brainstorming；Chain of Ideas 则把已有发展组织成研究轨迹 [16–18]。这些方法为已有研究的可能延伸设置了不同先验。更结构化的检索可以提高相关性，也可能把注意力限制在文献充分的方向。

扩大输入范围并不能消除对表示方式的依赖。MOOSE 从网页语料提取背景与启发，生成社会科学假设；SciAgents 通过本体图谱与专家 agents 连接概念 [19, 20]。它们的机制与通用构思有关，但对社会科学假设的判断、仿生材料领域的展示，并不能证明向 AI 研究迁移。尤其是，图中的关联只提供候选类比，不构成所提机制有效的证据。

数据驱动方法引入了目标更容易观察的反馈循环。HypoGeniC 维护自然语言假设，用带标签样本检验预测，再利用错误和受 bandit 启发的规则更新；HypoRefine 将文献假设与这一过程结合，比较假设修正及集合合并等方式 [21, 22]。分类场景允许留出集预测评价，为语言主张与观察结果建立连接，但预测规律可能仍只是相关性，而且研究问题由外部给定，并非系统自主发现。

## 3.2 人类控制与重组单位

Scideator 将论文拆为目的、机制和评价 facets，让用户选择、检查新颖性证据并修改组合。其被试内研究在相同底层 LLM 下比较 facet 表示与论文级交互 [23]，因此证据对应界面和表示方式，而不是笼统归因于更强模型。这也为人类保留了判断陌生类比及其相关性的空间。

IdeaSynth 同样通过文献反馈支持 facet 的变化与组合，CoQuest 则在人机互动中考察 breadth-first 与 depth-first 的问题发展方式 [24, 25]。它们提示，构思常常是反复调整约束的过程，并非一次输出完整问题。不过，用户控制、感知到的创造力支持和最终科学效用是不同结果。帮助研究者探索更多方向的工具，并不一定学会了选择值得执行的方向。

## 3.3 生成质量与筛选质量是两个问题

NLP 构思的大规模人类研究发现，LLM 提案可以获得较好的新颖性判断，但可行性较弱；进一步分析还发现，扩大生成规模会出现重复想法，模型排序也不可靠 [28]。这一发现意味着，大候选池只有在增加了有用替代方案、且 selector 能识别它们时才有帮助。流畅文本或更高采样温度都不能保证这两个条件。

IdeaBench 在参考论文背景下通过模型比较评价生成，LiveIdeaBench 则用极少关键词测试 divergent thinking [26, 27]。由于信息条件与目标行为不同，两者的分数回答不同问题。探索时发散很有价值，收敛到有依据、可检验的问题则是另一项要求。因此，比较应控制候选数量、信息访问和筛选预算，并分别报告候选池多样性与入选提案质量。

## 3.4 局限与开放问题

核心缺口在于：合理的提案不一定对应能解决未知的实验。文献新颖性检查、用户研究和预测测试各覆盖一部分，但没有一种能同时建立重要性、因果有效性和可行性。如何不继承既有 framing 而发现问题，如何超越文本 embedding 识别有意义的多样性，以及何时放弃吸引人但不可检验的想法，仍待研究。时间受限的文献检索也需要配套的模型污染审计。以下均为拟议研究，其预期优势仍是假设。

**表 3:** 不同构思场景暴露了问题形成过程的不同部分。

| 场景 | 机制或证据 | 尚未解决的关键步骤 |
|---|---|---|
| 文献延伸 [15–18] | 检索并重新组织已有研究 | 判断新延伸是否重要 |
| 跨概念假设 [19, 20] | 提取启发或遍历图谱 | 验证所提出的关系 |
| 数据驱动假设 [21, 22] | 依据预测反馈更新主张 | 从相关性走向有信息量的问题 |
| 人机共同构思 [23–25] | 用户操作问题组成部分 | 区分人类选择与系统能力 |
| 想法 benchmark [26, 27] | 参考文献背景或极少关键词 | 将感知创造力连接到可执行探究 |

### 3.5 拟议计划一：同时生成提案与有区分力的可执行 pilot

**研究假设与方法**。要求提案包含替代解释及可执行 pilot，有望提高真正解决某个明确未知的项目比例。生成器必须给出核心主张、合理替代解释、两种解释各自预期的观察，以及能够区分它们的最小比较。例如，声称校准改善时，应区分方法机制与额外调参的影响。固定 coding agent 实现 pilot，另设 checker 检查测量是否对应所声明的解释。

**任务与划分**。使用十二个有边界的 AI 研究情境，覆盖冻结小模型的校准、检索评分和受控输入变化下的鲁棒性。六个用于开发提示和检查实验基础设施，另六个采用不相交的数据集与代码模板家族并封存。允许开发集 pilot 反馈，但在独立评价种子和测试样本开放前冻结主张与分析规则；pilot 不得访问最终测试集。

**基线、指标与风险**。比较普通提案、带文字实验计划的提案，以及带有区分力的可执行 pilot 的提案；匹配总推理与实验预算，pilot 执行计入后者。分别消融替代解释和独立 checker。测量可执行性、盲评的区分能力、可复现的主张判定、置信度校准和每个有信息量结果的成本，将无法定论与实现错误分开。风险包括偏爱容易问题、pilot 统计效力不足及 checker 奖励格式合规；脚本成功运行但比较无效，不能算成功。

### 3.6 拟议计划二：将探索能力与筛选能力分开测量

**研究假设与方法**。机制层面的多样性只有与能识别有用差异的 selector 配合，才会改善下游产出。将普通采样、检索生成和受控 facet 重组三种生成器，与随机、直接提示、证据驱动三类 selector 交叉比较。每种生成器在相同 token 与检索预算内产出二十四个候选，冻结候选池后再应用各 selector，以区分生成、筛选及二者交互的影响，而非只比较完整 pipeline。

**数据、消融与测量**。复用上述开发与封存情境，在评价留出候选池前固定所有选择。盲态标注者依据实质机制聚类并识别有效替代方案，embedding 仅辅助标注。对每个 selector 的前三个候选及独立随机审计样本执行相同 pilot 协议。比较仅扩大候选数量、embedding 去重，以及去掉新颖性检查的 facet 重组。报告有效机制覆盖、重复负担、top-$k$ 有信息量产出和成本；记录抽样概率的随机审计有助于发现所有 selector 都遗漏的候选。

**失败风险**。机制标签可能主观，selector 也可能偏爱自身生成器的语言风格。应交叉使用不同模型，报告标注分歧，并在保留原始表达之外增加规范化评价条件。由于仅执行候选子集，不能声称得知候选池的 oracle 最优解或精确 selection regret。若文本聚类数量增加却未提高经验证的产出，则不支持研究假设。

## 4 Q3：如何把问题转化为可靠知识？

执行把研究提案与真实观察连接起来。程序可能成功运行，却检验了错误的命题；实验可能提高指标，却没有解释原因；报告可能准确描述了一个被选中的结果，却隐藏了失败尝试。因此，方法目标是建立从问题到干预、观察，再到适当限定的结论的可追溯链条。

**表 4:** 不同执行机制针对不同失效环节。这是设计比较，不是系统排名。

| 机制与例子 | 主要决策 | 反馈 | 仍由外部提供的条件 |
|---|---|---|---|
| 代码搜索：autoresearch、AIDE、R&D-Agent | 尝试哪个程序 | 测量的任务分数 | 任务重要性、evaluator 有效性 |
| 假设树：Arbor | 完善哪个分支 | 产物与证据 | 初始目标和评价设置 |
| 实验设计：AutoRA、DAD | 获取哪次观察 | 模型拟合或信息目标 | 变量、实验接口、建模假设 |
| 过程验证：Curie | 实验步骤是否合格 | 设置、执行与记录检查 | 科学检验是否充分 |
| 序贯检验：POPPER | 检验哪个蕴含命题 | 条件统计证据 | 正确蕴含与检验假设 |
| 程序或证明搜索：FunSearch、AlphaEvolve、Aletheia | 修订哪个构造或论证 | Evaluator、verifier 或 critique | 意义与验证范围 |

### 4.1 搜索候选解与选择实验

Karpathy 的 autoresearch 提供简洁 baseline：修改训练程序，运行受预算限制的实验，测量结果，保留有效改动。AIDE 把分支选择显式化，在可执行候选方案之间选择新建、调试或改进；R&D-Agent 则把改进思路的提出与实现分开 [29–31]。这些设计便于分析 engineering gains 来自哪种搜索策略，也暴露了以指标提升作为科研目标的限制：任务、指标和可操作环境已经给定。强优化器未必知道某个干预为什么有效。

Arbor 用持久化树组织假设、产物和实验证据，使分支选择能够依赖已有观察 [32]。这种表示适合研究 scientific state：哪个假设仍然合理，哪个结果已经复现，哪个方向已经耗尽预算。关键比较不只是树结构与线性对话，而是在匹配提案数、实验数和模型调用后，结构化状态是否改善了特定决策。当前任务主要仍是对给定产物和目标进行改进。

AutoRA 使用另一种分解：experimentalist 选择测量，experiment runner 获取观察，theorist 更新模型。Deep Adaptive Design 在部署前学习 sequential Bayesian experimental design policy [33, 34]。这两类工作把注意力转向 “哪次观察有用”，而非只看 “哪个实现分数最高”。其假设也很关键：变量、可执行实验、模型类别或概率假设需要先被指定。向开放科研扩展时，系统还要决定哪些竞争解释应进入这一空间。

### 4.2 可靠性不止是成功运行

Curie 检查实验设置与执行，约束 agents 之间的状态转换，并维护结构化实验记录 [35]。它区分 implementation alignment 与 conclusion correctness，这说明可运行代码并不足够。其评价结合自动评审和人工检查，因此应把 rigor modules 当作可研究的机制，而不是每条被接受结论都有效的保证。

POPPER 通过可测量蕴含的检验和 sequential evidence aggregation，研究给定自然语言假设的验证 [36]。统计保证以有效的逻辑蕴含和条件检验为前提。如果实验实际检验的是另一个命题，或自适应复用数据后假设不成立，外层统计机制不能补救科学错误。针对一个假设的错误控制，也不能写成对无限生成命题集合的 false discovery rate control。这提示我们在接口中分别处理语义检查、可执行 controls 和统计检验。

### 4.3 数学能提供什么？

FunSearch 与 AlphaEvolve 把程序生成、可执行评价和演化选择结合起来 [37, 38]。当目标具有精确 evaluator 时，紧密的 proposal–verification 循环十分有用。Evaluator 本身也是重要的人类贡献：如果没有检查正确性，agent 不能从程序运行快就推出算法有效。有限数值测试、有限构造的穷尽检查和数学证明，支持的是不同主张。

Aletheia 在自然语言中迭代生成、验证和修订数学推理，并报告不同程度的人类参与 [39]。它的输出不能统一写成 formally verified proofs。把本文方案扩展到数学时，应分别研究 conjecture choice、proof search 和 verification。例如，proof assistant 可以检查一个受限的形式命题，而数学家判断解决它是否带来贡献。形式化环境提供有效性检验工具，不会自动给出科学重要性。

### 4.4 完整系统暴露环节之间的依赖

The AI Scientist 利用人工实验模板，把构思、代码、实验、写作和评审连接起来。Version 2 使用更一般的实验管理器与 agentic tree search，并报告有限的 workshop 投稿研究 [40, 41]。这些证据说明工作流能够被整合并产出可评审材料，但没有单独识别哪个模块产生科学价值，也没有建立通用选题能力。

AI-Researcher 整合文献、实现和报告，Scientist-Bench 区分 guided innovation 与研究主题内部的探索。Agent Laboratory 则把人工提供的 idea 和中间反馈纳入流程 [42, 43]。人类输入应当是实验变量，而不是在描述 autonomy 时省略的因素。公平比较需要记录谁选题、谁修复代码、谁解释模糊结果，以及谁决定停止。

Co-Scientist 围绕科学家给定的目标演化假设，并在生物医学案例中开展后续实验。Kosmos 使用结构化 world model，协调更长程的文献与数据分析 [44, 45]。两者都说明长流程需要持久的科学状态，也要求准确记录目标、数据、领域知识和外部验证由谁提供。可追溯报告更容易审计，但可追溯性不能单独证明每个命题正确且重要。

实际启发是研究模块接口。Idea generator 可能提出有用问题，但 executor 无法实现；executor 可能得到结果，但 writer 把结论写得过强。全面替换系统之前，可固定问题池和执行器，仅改变传递给执行器的表示。一个控制良好的接口实验，往往比同时改变模型和预算的整系统比较更容易解释。

### 4.5 局限与开放问题

大部分执行证据来自已有 evaluator 的给定目标。Agent 能否选择真正区分解释的实验，识别 inconclusive results，并在最终报告中保留不确定性，仍需检验。现有 validator 可以检查已经声明的 control，却可能发现不了遗漏的 control。即使每个实验都正确，大量变体搜索仍可能对 validation set 过拟合。长程研究还需要决定何时停止、何时求助以及何时修改问题，这些都是科研决策。

### 4.6 研究方案 I：选择有区分力的实验

**待验证假设与方法**。检验显式维护竞争解释，能否比只优化分数的 agent 做出更好的实验选择。每个问题记录至少两个假设、它们对候选干预结果的预测，以及解释结果所需的前提。根据预测分歧选择成本可承受的干预；只有在 likelihood 合理时，才使用 Bayesian information gain。保留“尚不能确定”的选项，不把 LLM 的自报信心强行当作 posterior。

**具体 pilot**。作为待验证的设计选择，拟用小型表格模型和紧凑图像分类器构建十八个场景，来自六个模拟器家族，每个家族三个实例。家族之间改变数据生成和评价机制，而不只是随机种子；构建、开发、测试各分配两个完整家族。候选解释包括额外训练步数、预处理泄漏、类别不平衡和有效 augmentation。隐藏的参考实现定义实际生效的单个或多个机制。评价前预先登记允许的干预，用独立种子的反事实检查，确定在该模拟器及声明的效应容差内哪些解释可以区分。注入一个因素本身不代表解释具有唯一可识别性。加入机制共存、干预下无法区分，以及所有候选解释均错误的案例；证据不足以确定唯一答案时，允许返回相容解释集合或弃权。

**Baselines 与测量**。将拟议选择器与随机实验、固定 ablation checklist、贪心 validation-score search，以及不显式维护假设的 agent 比较。五种方法使用相同干预权限、模型、工具和代码生成模块。只在可识别案例上评价正确机制恢复率；其他案例评价相容解释集合的覆盖与多余成员、错误解释，以及弃权时的错误率–覆盖率权衡。同时记录多余实验和跨场景家族的迁移。在开发案例上分别移除假设集合、预测表和结果更新规则，测试前冻结 oracle、提示与停止规则。

**预算与核算**。六个测试场景各运行三个种子，五种方法合计九十次目标运行。每次最多四个干预，实验计算不超过十五个 worker-minutes；声明硬件为四核 CPU、16 GB 内存，图像任务最多附加一张 24 GB GPU。目标评价上限为 22.5 worker-hours、九十 CPU core-hours；若每次全程分配 GPU，则至多 22.5 GPU-hours，实际 CPU 与 GPU 使用量需分别报告。模拟器与 oracle 构建、开发各另设十个 worker-hours 的上限。远程模型计算不包含在设备时间中：每次目标运行最多 40,000 输入和 8,000 输出 token，另记 API 成本。失败、截断、oracle 检查和开发消融都需计入，不能因为未产生有用结果而从账目中删除。这些是 pilot 上限，不是实测需求或统计功效计算。

**失败风险**。合成世界可能使解释过于清晰，或通过模拟器痕迹泄露机制。需隐藏参考代码和机制标签，公开模拟假设，并检查收益能否延续到留出的生成器。六个测试场景仅来自两个家族，不确定性和迁移结论必须反映独立分组很少的限制。在此获得改进，只能支持 diagnostic benchmark，而非通用科学推理。下一步里程碑是通过盲审，检验所选 controls 是否帮助解决真实复现分歧。

### 4.7 研究方案 II：从 claim 到 evidence 的检查

**待验证假设与方法**。检验 structured claim ledger 能否减少证据不足的结论。每个 claim 必须指向 run identifier、代码版本、数据划分、统计量，以及支持它所需的 control。确定性 checker 验证产物和数值是否一致；独立 critic 检查实验是否区分了所声称的解释。Critic 可以标记 unsupported 或 inconclusive，但不能修改实验输出以迎合结论。

**数据、对照与评价**。拟采集十二个来源任务的二十四次完整调查，每个任务两条轨迹，取自方案 I 或来源可检查的兼容公开轨迹。开发与测试各分配六个来源任务，相关生成器家族放在同一分区。每次调查选择五条原始 claim，各构造一个扰动版本，包括改写数值、遗漏 control、混淆 validation 与 test 或加强结论，总计最多 240 条固定 claim，每个分区 120 条。由两位不知道方法条件的评审分别标注 supported、unsupported 或 inconclusive，再裁决分歧；被扰动不自动等于无效。样本保留未经改写的自然错误与不确定案例。

在检查实验中，同时冻结实验产物和这一固定 claim 集合。比较全部接受的 accept-all/no-check、prompt-only critic、仅确定性检查与组合 ledger。所有方法看到相同的可用证据，并为每条 claim 返回判断，因此错误检出和误拒绝使用共同分母。分别报告 precision、recall、有效 claim 保留率及对 inconclusive 的处理。原始 claim、扰动版本和来源调查必须位于同一分区；不确定性按来源任务聚类，不能把句子当作独立样本。

**归因与成本**。在十二次留出调查上另做 writer 实验，比较普通 writer 与 ledger 引导的写作。实验产物保持固定，为两种 writer 使用同一份经独立标注的、证据能够支持的 claim 清单，评价有效内容覆盖及新增的无依据断言；当两者生成不同 claim 时，不比较它们的 detection score。这样区分检查与生成，也避免什么都不说获得满分。未来允许 checker 请求新实验的研究，应另行评价调查能力的改善。

每种检查或写作条件采用三个随机重复。四种检查方法处理十二次调查，共 144 个检查批次；每批本地资料处理最多五个 CPU worker-minutes，合计十二个 worker-hours。两种 writer 生成七十二份报告，使用相同的每份时间上限，再增加六个 worker-hours。每次留出调查允许一次独立重跑，每次最多十五分钟，至多增加三个 worker-hours，必要时增加三个 GPU-hours。每种检查与写作条件在开发集运行一个重复，另设六个 worker-hours 上限。因此，在相同四核硬件上，完整本地 pilot 的上限为二十七个 worker-hours、108 CPU core-hours；远程语言模型计算单列，每个检查批次或报告最多 40,000 输入和 8,000 输出 token。人工标注、模型调用、产物缺失和重跑失败均需与成本一并报告。工具故障和 critic 错误不是科学假设为假的证据，同一来源任务上的重复也不会增加独立任务的数量。

## 5 Q4：研究经验如何改善研究者？

科研系统可以改进当前方案，却未必更善于开展下一项研究。Q4 关注这一区别：一次研究结束后留下什么信息，改变哪个组件，又能否帮助后续决策。我们区分任务内适应（within-task adaptation）、相关任务之间的跨运行复用，以及向留出任务族的迁移；它们是不同评价设置，不能互换。持久数据库能够支持前两者，却未必证明第三者；单个问题中的参数更新也可能完全局限于当前任务。科研品味还需要额外检验哪些问题值得投入，而不只是更高效地解决给定问题。

### 5.1 外部记忆、可复用技能与局部反思

AgentRxiv 让后续科研智能体读取既往研究报告；Agora 用 Git 记录共享假设、结果及核验关系 [46, 47]。两者把科研视为持续积累的集体过程，区别于普通对话历史的关键是跨会话持久化与复用。然而，持久化本身不能识别记忆的因果贡献：后续智能体也可能只是获得更好的候选解、更多累计计算或更充分的任务内证据。Agora 明确指出，单位算力的发现收益仍需匹配对照。

**表 5:** 经验改变什么？机制与迁移是不同问题，同一工作可以采用多种机制。

| 机制 | 改变的对象与时间范围 | 代表性工作 |
|---|---|---|
| 局部反思 | 一次研究内的上下文与行动选择 | Reflexion；Dolphin；OR-Agent |
| 记忆与技能 | 后续会话复用的外部证据或程序 | AgentRxiv；Agora；EvoScientist；InternAgent-1.5；AutoResearchClaw；HypoForge |
| 程序演化 | 控制器代码或科研循环策略 | ADAS；Darwin Gödel Machine；Bilevel Autoresearch |
| 参数训练 | 任务前或任务中更新的模型权重 | CycleResearcher；ResearchTrails；SciSense；MLE-Ideator；TTT-Discover；EFT |

EvoScientist 区分构思记忆与实验记忆，从轨迹中提炼研究方向和实现策略；InternAgent-1.5 则组合程序化策略、轨迹内实验片段与跨会话语义知识 [48, 49]。这些架构启发我们区分记忆中的发生了什么、为何选择该行动和经验何时适用。这是本文的设计解释，并非已经验证的通用记忆格式。AutoResearchClaw 强调从先前失败中提炼经验，其跨运行消融主要支持避免已知失败模式，而非提高科学质量上限 [50]。

可复用技能（reusable skills）不仅存储报告，还描述在可识别条件下应采取的行动。HypoForge 根据比较式批评和执行反馈修订假设生成、检验技能，在不更新基础模型的情况下评价留出任务 [51]。这种策略适应有研究价值，但其检验通过率包含参考假设达到显著性的要求，不能单独确立假阳性控制或选题重要性。技能可能学会满足评价器，却仍不擅长产生有信息量的科学证据。

局部反馈也应保留独立定位。Reflexion 无需参数更新即可保存语言反思；Dolphin 将实验分析反馈给下一轮；OR-Agent 在启发式搜索中使用分层反思与回溯 [52–54]。它们为根据反馈调整行动提供基础，但不能把各自的实证范围改写为通用跨任务科研学习。尤其是 OR-Agent 的语言梯度、动量只是对反思机制的类比，并非对语言模型进行梯度更新。

## 5.2 改变科研程序，还是训练模型？

代码演化改变产生后续行动的过程。ADAS 根据既有设计与评价档案搜索智能体程序；Darwin Gödel Machine 维护能够修改自身实现的编程智能体档案 [55, 56]。二者为科研智能体设计提供基础，但证据来自给定基准，而非科学议程选择。Bilevel Autoresearch 进一步把内层科研循环本身作为优化对象：外层分析轨迹，生成改变搜索方式的机制 [57]。其报告实验限于一个小型 GPT 预训练场景，展示的是有界的外层干预内层，而非无限递归自我改进或通用跨领域迁移。

参数训练改变提出或评价决策的模型。CycleResearcher 利用自动审稿器开展研究生成的迭代偏好训练 [58]。其核心评价包括模型生成但未执行的实验结果，附录另展示了与执行模块结合的案例。因此，稿件或审稿分数改善不能解释为实证发现能力改善。对训练数据而言，这一区别同样关键：流畅的事后解释未必记录了一场真正发生的实验。

ResearchTrails 从人类 Git 历史提取决策序列，研究示例、技能提炼、监督学习与强化学习 [59]。其主要预测目标是记录中的下一步科研决策。提交历史只是人类探索的不完整证据，与历史决策相似也不能证明另一种策略会获得更多发现。SciSense 则合成基于引用文献的 sensemaking 轨迹，包括朝向已知贡献的路径重建，并将其蒸馏进规划模型 [60]。这种重建能够提供结构化监督，却不是作者真实思考过程的观测；其下游执行实验与判断型评价也仍窄于通用科学价值。

MLE-Ideator 提供更直接的执行信号：构思模型通过强化学习学习策略指导，由另一智能体实现建议 [61]。留出的 MLE 任务检验指导能力能否迁移，但目标仍由外部给定。TTT-Discover 在单个问题的搜索中更新模型参数，Evolution Fine-Tuning 则先从进化轨迹训练，再评价留出的优化任务 [62, 63]。这一对照区分了任务局部适应与跨任务经验训练；EFT 的给定目标和主要采用的共同搜索框架，仍限制了对陌生科研工作流及 taste 的推断。

### 5.3 现有证据的限制与开放问题

贯穿这些机制的核心难点是归因。更好的最终产物可能来自更多尝试、检索到的答案、更强的执行器，也可能来自更好的决策策略。因此，评价需说明保留了什么，尽可能固定执行接口，同时比较相同在线预算与包含经验采集的总成本；任务间是否重置记忆、权重也必须明确。如果训练和测试共享数据集、代码仓库或高度相似的任务模板，仅划分轨迹并不足够。

由此产生三个问题：什么经验能保留决策理由和适用条件，而不是复制成功答案？环境改变后，研究者能否修订曾经有效的策略？即使最终基准分数没有提升，学习能否改善信息性实验的选择和停止决策？回答这些问题需要真实执行与独立核验，不能只依赖同时提供训练奖励的评审器。下述两个 pilot 均为拟议设计，并非已报告结果；任务数和预算是有意控制规模的起步假设。

### 5.4 拟议方案 A：识别科研记忆的因果价值

**假设与方法**。同时保存成功和失败尝试的结构化决策记录，比润色后的报告摘要更可靠地改善后续实验选择。建立固定档案，记录状态、候选行动、当时理由、实际结果与尚未解决的不确定性。区分实现错误、证据不足和反驳假设的证据，避免统称为失败。将同一档案转换为文字摘要或结构化记录，保留来源链接；目标评价前冻结档案，防止不同条件相互污染。

**数据、划分与对照**。作为 pilot，拟从表格预测、图像分类和小型语言模型训练中选择十二个使用公开数据的小任务。每个任务族分配两个任务构建档案、一个开发、一个作为隐藏目标，底层数据集及数据划分在这些角色间互不重叠。先确认任务可运行，再预先登记任务身份。在相同目标与随机种子上随机分配六个条件：无记忆、完整文字摘要、仅成功记录、仅失败记录、完整决策记录、打乱任务对应关系的完整记录。摘要与完整记录使用相同底层证据，成功与失败对照用于隔离内容贡献；非空条件统一检索策略与记忆 token 上限。打乱的是任务与记忆的对应关系，而非记录顺序，同时保持数量和长度，以检验相关经验是否重要。

**指标与资源核算**。每个目标任务运行三个种子，仅按验证数据选择最终产物，记录其经独立核验的测试结果、重复失败率、冗余实验、无效结论，以及达到预先指定验证改进所需的时间。对抽样决策日志开展盲审，检查实验是否针对当时的不确定性。统一硬件，每次最多六个实验、45 分钟任务计算；如果每次始终占用一张设备，主要目标对照的上限为 40.5 device-hours。每个来源任务采集两次运行，每个开发任务及条件运行一次，分别增加九个和 13.5 个 device-hours 的上限。摘要、检索、模型 token 与失败执行另行核算，并报告实际设备利用率和 API 成本。这些设备时间上限不含远程模型计算，后者仍须计入成本。

**失败风险**。相似任务可能把记忆变成答案缓存；结果标签可能把低检验力误写成负发现；长记录也可能只是通过额外上下文产生帮助。打乱对照、来源检查和匹配证据只能部分缓解这些问题。目标任务仅有三个，区间应按任务聚类，并作为探索性结果解释。如果无收益能够区分防错帮助与科研决策改善，同样具有研究价值。

### 5.5 拟议方案 B：跨留出任务族蒸馏科研策略

**假设与方法**。从决策状态、备选行动、实际结果及适用条件训练，比仅模仿下一步行动更能迁移。固定实现智能体与评价器，仅改变策略模型。先用小型开放模型进行参数高效监督微调，待监督信号显示收益后再考虑强化学习。每个训练结果必须链接真实执行日志；未执行的合成理由可以作为注释保留，不能充当观测或行动成功的证据。

**数据、划分与比较**。拟构建十六个任务，表格预测、图像分类、小型语言模型训练和数值算法优化四个任务族各四个。按整个任务族留出：两个用于训练、一个开发、一个测试；每个任务内部再分离模型拟合数据、可见验证反馈与封闭最终评价。初始 pilot 只采用一个预先登记的任务族划分，通用迁移结论还需要进一步轮换。每个训练任务最多采集六条短轨迹，每条包含四次实验决策，合计最多 192 个实际执行的决策转移。比较基础策略模型、从同一档案检索的基础模型、仅行动微调、完整决策上下文微调；使用相同决策转移样本与优化步数预算，报告 token 数并在开发集增加匹配 token 的对照，再消融结果信息或适用条件。

**指标、成本与解释**。在留出任务族上冻结全部学习组件，四个目标任务各运行三个种子，每次最多四个实验、30 分钟；单设备执行时，四种方法的目标对照上限为 24 device-hours。监督微调的初始上限设为已声明硬件上的八个 device-hours。教师轨迹、筛选、开发、训练和推理分别核算，同时报告成本分摊到不同数量未来任务后的表现。主要指标是独立核验的任务改进及单位总预算收益；次要指标包括无效实验、过早停止和对评价器接口变化的敏感性。训练样本少、任务族惯例及数据污染都可能制造或掩盖迁移。即使结果为正，它支持的也只是给定目标下可复用的实验策略，而非自主选择重要科研问题。

# 6 Q5：如何评价更好的科研？

评价 AI researcher，首先需要说明哪些决策由 agent 作出、哪些条件由评估者提供。答案正确、模型改进、结果复现与问题值得研究，是不同的成就。现有评价工作提供了测量科研不同环节的工具，而非统一的科学能力刻度。本节按输入条件、决策自由度和验证程序组织这些工具，再提出把问题质量与后续证据连接起来的研究方案。

## 6.1 现有评价实际测量什么

MLAgentBench 通过文件操作、代码执行和迭代式模型改进，使实验过程可被观察；MLE-bench 将此类行为放入源自 Kaggle 的预测任务；MLGym 则支持更多任务环境和研究产物，包括算法研究场景。三者共同提供可执行的反馈循环，但任务与成功标准仍由外部给定。MLGym 明确区分其 baseline-improvement benchmark 与更高层次的科研能力。AIRS-Bench 从论文中构建任务且不提供基线代码，增加了实现自由度，却仍指定问题、数据集与评价指标。这些变化扩大了执行难度和范围，并不意味着问题选择已由 agent 自主完成 [64–67]。

RE-Bench 引入人类专家尝试，并比较时间预算和重复尝试的不同分配方式，说明性能结论需要注明资源条件，不能只比较单个最高分。FML-bench 则控制代码编辑和执行基础设施，隔离“下一步尝试什么”的研究决策，将验证反馈与最终 held-out test 分开，并记录搜索行为。其实验步数预算并不等于所有推理成本相同：额外 reasoning calls 仍会消耗资源。这两类设计帮助区分工程基础设施、科研策略与可用计算机会 [68, 69]。

复现提供了另一种可测量目标。CORE-Bench 从已有计算研究产物出发：easy 设置直接提供输出，更难设置则逐步增加环境配置与实际运行要求。PaperBench 从论文及补充说明出发，要求实现方法，并分别评价代码开发、执行和结果匹配；其 Code-Dev 变体省略复现运行，因此支持的结论更窄。PaperBench 还使用人工标签独立评价自动 judge。复现已有产物与依据论文独立实现是互补能力，二者均不能确立新选研究问题的价值 [70, 71]。

ScienceAgentBench 区分程序成功运行与满足科学任务的输出要求，其检查采用任务特定标准，并未给出科学发现的统一定义。SciCode 测试通过可运行程序表达科学知识的能力，包含子问题结构，以及是否提供科学背景或中间答案等不同设置。DiscoveryBench 进一步评价假设内容，把发现的关系分解为多个 facets，再与参考发现比较。这些工作分别强调科研流程可靠性、scientific coding 和数据支持的发现恢复，但仍保留外部指定的任务或发现目标 [72–74]。

交互环境让调查过程本身成为评价对象。ScienceWorld 测试基础科学中的行动式实验；DiscoveryWorld 分别评价任务完成、相关研究步骤和解释性知识，其中知识评价依赖参考内容。受控世界便于检查干预行为，但向真实科研迁移仍是额外问题。FrontierMath 提供答案可自动核验的高难度数学问题；原始 benchmark 不要求形式化验证证明，也不要求 agent 自主选择猜想。易于验证使这些环境有价值，却不会自动让其分数成为科学重要性的度量 [75–77]。

MLR-Bench 在给定研究主题内，将输出扩展到 idea、proposal、实验与论文，并采用结构化 review rubrics；这让预测准确率之外的质量进入评价，同时也使 judge calibration 和独立验证更加必要。Many AI Analysts, One Dataset 提供了互补的方法学研究：固定数据、假设与 estimand，改变模型和 persona 后，分析路径及结论仍会变化。AI auditor 可以过滤方法错误，却无法穷尽人类可接受的分析路径，也不能为每个保留结果提供正确性证明。因此，科研质量不仅取决于最终报告，也取决于生成分析和评价分析的程序 [78, 79]。

| 评价类别 | 给定内容 | Agent 决策 | 核验对象 | 尚未覆盖 |
|---|---|---|---|---|
| MLAgentBench；MLE-bench；MLGym；AIRS-Bench | 任务、数据、指标；初始代码因设置而异 | 模型、代码与实验 | 任务表现 | 问题价值 |
| RE-Bench；FML-bench | 有限任务与初始方案 | 改进及搜索 | 分数与过程 | 研究议程选择 |
| CORE-Bench；PaperBench | 研究产物或目标论文 | 配置或实现 | 输出或复现要求 | 新贡献 |
| ScienceAgentBench；SciCode | 科学任务与输入 | 程序与分析 | 执行与任务测试 | 问题重要性 |
| DiscoveryBench；MLR-Bench | 发现目标与数据，或研究主题 | 假设或研究方案 | 参考 facets 或评审 rubric | 独立确立的价值 |
| ScienceWorld；DiscoveryWorld | 模拟世界与任务 | 行动与实验 | 任务与过程；后者另评解释 | 真实世界迁移 |
| FrontierMath | 数学问题 | 推理与计算 | 提交答案 | 证明与猜想选择 |
| Many AI Analysts | 数据、假设、estimand | 分析设定 | 经审计的结果变异 | 完备的有效性验证 |

**表 6:** 评价工作的决策范围与证据边界。合并行概括相关工具，不表示其协议可互换；Many AI Analysts 是实证研究而非 benchmark。

### 6.2 从评分到有依据的比较

我们建议报告多维结果：问题价值、方法有效性、执行成功、可复现性、泛化能力与资源消耗。单一综合分数可以作为补充，但需公开权重。Judge agreement 应在独立保留的人工标注上评价，同时记录分歧和对无支持主张的错误接受；表面一致不等于 ground truth。比较时应固定模型访问、检索条件、可用数据与停止规则，并分别报告 inference tokens、实验计算量、wall time、并行度和人工协助。所有尝试都应纳入资源核算。Best-of-many 结果需要计入筛选成本，依据 validation 选择方案后仍需独立最终测试。任务、评价器、环境版本与完整轨迹归档，使这些结论可以检查。

### 6.3 局限与开放问题

现有工具留下一个核心缺口：benchmark 可以测量在有价值任务上的进展，但任务的价值可能早已由人类选择。基于参考答案的评价可能拒绝有效的新发现，开放式评审又可能偏好有说服力的表述。公开任务可能与预训练或检索材料重叠；新任务能够减少可观察的暴露，却不能证明训练独立性。科学价值也可能在后来被他人使用时才显现，而负结果即使不改善预测指标，也可能提供信息。如何以前瞻方式测量这些性质，同时维持可负担、可重复的比较，仍是开放问题。

### 6.4 拟议项目一：从 idea 到结果的前瞻评价

**尚未验证的方案与设计**。构建包含 generation 与 selection 两条独立赛道的前瞻 AI research benchmark。在结果产生前，预注册宽泛研究 brief、候选资格、预算，以及重要性、新颖性、可检验性和证据质量 rubric。按相同配额收集人类与 AI 的候选问题，然后冻结文本及来源信息。所有 selector 对同一冻结候选池排序；generation 赛道另行评价各 generator 提供的候选。这样可以避免把更好的执行能力或更有利的候选池误认为更好的选题能力。

**数据划分与对照**。按研究主题和数据集、代码谱系划分开发集与测试集，并在 agent 开发完成后收集最终前瞻任务批次。隐藏实验测试数据，冻结文献快照并记录后续所有检索。Baselines 包括随机选择、固定 novelty/feasibility heuristic、one-shot model、使用相同基础模型的迭代 agent，以及专家排序。对候选问题进行随机分层抽样，由不了解提案来源和选择分数的独立执行者，在统一资源下运行。已知抽样概率支持对选择偏差作调整；失败、不可行及结论不明确的尝试都保留为显式结果。

**结果指标与归因**。独立评审者先在不知道实验结果时评价问题价值，再依据冻结 rubric 审查匿名 evidence packages；由另一轮独立复现检查核心发现。报告排序与后续价值评估的一致性、可行性预测校准、单位预算的有效发现、复现结果，以及有信息量的负结果。分别记录事前潜力和事后证据。使用共同 executor 比较被选问题，以隔离 selection；固定问题比较不同执行方案。消融文献访问、迭代 critique 与仅来自开发集的执行反馈，并计入全部成本，而不只对齐候选数量。如果研究目标任务上的 pilot 反馈，应另设独立 track，明确 pilot 预算，在 pilot 后冻结排序，并将独立的最终结果封存至评价时；其结果不得与执行前的选择混合统计。

**不确定性与失败风险**。采用多个 agent seeds 和多位评审者，按主题或问题聚类估计不确定性，避免将重复实验运行当作独立科研成功。报告评审分歧及对 rubric 权重的敏感性。隐藏的先前暴露、执行者专长差异、选择性执行和不断变化的新颖性标准仍会带来风险；应保留访问日志与裁定记录，并将结论限制在抽样研究分布内。看似较弱的 idea 也可能产生有用证据，因此不应仅以正向效应定义选题质量。

### 6.5 拟议项目二：科研评价的稳健性

**尚未验证的方案与任务构建**。围绕已经独立检查代码、输出与主张的研究包，构建配对 stress test。结合真实分析和已知数据生成过程的模拟，后者提供已知 null 与 effect。固定 estimand，枚举合理的预处理及建模方案。建立两类独立扰动集：保留科学含义的排版、顺序及修辞置信度变化；以及实质性 negative controls，例如在已知 null 下不受证据支持的正效应主张。同时加入正确报告 null findings 的有效对照：null data 或负结果本身并不意味着研究包无效。领域专家需确认哪些扰动保持含义、哪些扰动应改变结论。

**划分、基线与指标**。按原始论文、数据谱系和扰动模板划分数据，保留未见组合用于测试。比较固定预注册分析流程、适用时的可执行检查、rubric-based LLM judges、多 judge 系统，以及分层子集上的盲法人工评价。测量错误接受与错误拒绝、等价表述下结论的不变性、对确实无效证据的敏感度，以及合理分析之间的结论分布。报告原始与纠正后的结果分布，不把所有 multiverse 分歧都解释为错误，也不把共识等同于证明。

**消融、成本与不确定性**。固定研究产物、改变 judges，再固定 judges、改变分析选择，从而区分评价不稳定与执行不稳定。消融对轨迹、可执行结果和修辞文本的访问。按包含全部分析分支和 judge calls 的总预算进行比较，同时报告质量–成本曲线；增加投票的系统还应与等成本 resampling baseline 比较。采用按来源任务聚类的配对不确定性估计，同时报告平均及最差组稳健性。失败风险包括无效 null controls、暗中改变科学含义的扰动、auditor 的共同盲点和有限的 multiverse；应独立审计抽样案例，并保留无法裁定的情况，而非强行给出二元正确性标签。

## 7 可执行的研究议程

前面的十项方案是一组选择，而不是同时开发十个系统的计划。合适的首个项目应当隔离一种决策，复用可检查的 executor，并且在新方法失败时仍能产生知识。我们建议从表 7 的三个项目中选择。这个顺序属于本文的实践判断：先获得可信轨迹，再研究选择，之后才训练更一般的策略。

### 7.1 先明确研究的最小单位

最小有用产物是一张 question card 加一份 experiment record，而不是生成的论文。表 8 给出一个例子。它适合用来调试研究基础设施，不代表新颖科学方向。Generator 可以生成 cards，selector 对其排序，固定 executor 执行检验。这种表示允许替换模块，同时避免悄悄改变任务定义。

对于 outcome-grounded taste，先使用简单 pairwise model，例如在固定表示上的正则化 Bradley–Terry ranker，再考虑训练大型生成式 judge。分别采集专家对问题本身的偏好和对已完成证据的判断，否则模型可能只学会识别容易实现的 proposal。价值、可行性、有效性和成本应分别报告，在引入聚合 reward 之前先检查敏感性。Active annotation 需要保留随机 audit sample，以发现模型很少主动查看区域中的错误。

**表 7:** 三个起始项目，以及值得继续扩展它们的证据。

| 项目 | 最小方法 | 首个有意义的结果 | 停止或修订的理由 |
|---|---|---|---|
| 1. 有用的科研记忆 | 有来源的决策记录；固定检索器和执行器 | 比证据匹配的 prose 和 shuffled memory 更少重复错误或更好决策 | 匹配上下文和证据后，收益消失 |
| 2. Outcome-grounded taste | 共享候选池；使用 pilot 结果和专家比较的 pairwise ranker | 在留出任务上，选中更多经独立检查且有信息量的结果 | 收益只反映容易实现或文风优势 |
| 3. 可迁移科研策略 | 在已执行决策轨迹上对小模型进行监督适应 | 在留出任务家族上优于 retrieval 和仅模仿 action | 计入数据采集或改变任务接口后，收益消失 |

**表 8:** 面向冻结 retrieval system 的示例 question card。若作为原创研究贡献，仍需进行新颖性核查。

| 字段 | 具体内容 |
|---|---|
| 未知问题 | Disagreement-based query rewriting 是否比单纯增加候选检索更能提高证据覆盖? |
| 竞争解释 | 收益来自额外 retrieval calls，而不是所提出的选择规则。 |
| 干预 | 原始 query、随机选择 rewrite、根据 disagreement 选择 rewrite。固定 encoder、corpus 和总调用数。 |
| 测量 | 已标注支持段落的 recall、盲审 support judgments、latency，以及 inference 与 retrieval 总成本。 |
| 划分 | 用开发 queries 调参；相关问题和来源文档成组划分；最终 queries 与 relevance labels 保持封存。 |
| 决策规则 | 报告配对效应与不确定性，区分有用增益、在检验范围内的负结果以及证据不足。 |
| 证据记录 | Query 来源关系、模型版本、段落标识、随机种子、输出，以及支持每个 claim 的具体比较。 |

对于 memory，archive 应记录尝试了什么、为什么尝试、发生了什么，以及经验何时适用。“方法 X 不好”这样的失败记录过于笼统。有用的记录应该指出收益在匹配 compute 后消失，链接所比较的 runs，并写明尚存的不确定性。先分别检验内容和表示，再添加复杂 retrieval 或 reflection agents。对于策略训练，监督 baseline 比标签与 evaluator 同时变化的 reward loop 更容易诊断。

## 7.2 分阶段实现与决策

**阶段 1：验证 executor 与记录**。选择现有硬件实际能运行的小型公开任务。先做 smoke tests，再固定最终任务集合，冻结依赖、模型版本、数据来源和 timeout。保存每次行动，包括失败尝试。实现确定性的产物和指标检查，并人工抽查 controls 是否检验了所声称的命题。在独立重跑能够恢复关键测量之前，不启动策略学习。

**阶段 2：隔离拟议机制**。从 Q1–Q4 已定义的受控比较中选择一项，根据问题固定 executor、候选池或任务输入，以及预算。使用 development set 调试 prompts 和评价，然后冻结方法。前文的小规模 pilot 应视为 feasibility study：报告每个任务的结果、效应量与不确定性，不依赖一个名义显著性阈值。多个随机种子可以降低随机噪声，但不会把三个测试任务变成广泛的研究总体。

**阶段 3：检验一个重要边界**。在初始设置中获得可信结果后，每次只改变任务家族、backbone、evaluator interface 或数据分布中的一项。Memory 方法需要在相关分布变化下有效，而不是复用答案；taste model 在规范化表述后仍应选中有用问题；planning 方法在换掉原有 coding agent 后仍应保留价值。负结果能说明方法的哪部分依赖初始条件。

**阶段 4：前瞻地评价新问题**。完成前几个阶段后，再让系统生成尚无完成结果的问题。冻结候选文本与知识访问，按公开规则分配执行预算，由独立评审检查匿名证据。跟踪有用负结果和后续问题，而不只统计正向指标变化。这一步对于更强的科研判断力主张是必要的，但它仍是在有限研究分布上的评价，而非科学重要性的完整测量。

### 7.3 什么样的结果有说服力？

首篇论文可以建立一个明确而有限的主张：在匹配证据和上下文后，结构化 memory 减少重复实验错误；pilot-informed ranker 从固定池中选出更有信息量的问题；或者计入采集成本后，decision-context training 仍能迁移到留出的任务家族。应发布可执行任务定义、原始与处理后结果、决策轨迹、评价代码以及人类参与记录，并说明哪些更广泛的主张尚未检验。

共同的方法目标是把科研决策与后续证据连接起来，再检验所得经验能否超出原始任务。沿着这条联系，可以具体研究如何改善 research taste，而不预先把流畅提案、更长工作流或更高 benchmark 分数视为其完整测量。

## 参考文献


[1] Chris Olah. Research Taste Exercises. Chris Olah's notes, 2021. URL https://colah.github.io/notes/taste/. Essay / talk.

[2] Andrej Karpathy. A Survival Guide to a PhD. Andrej Karpathy's blog, 2016. URL https://karpathy.github.io/2016/09/07/phd/. Essay / talk.

[3] Richard W. Hamming. You and Your Research. Bellcore lecture; J. F. Kaiser transcript, 1986. URL https://www.cs.virginia.edu/~robins/YouAndYourResearch. Essay / talk.

[4] Michael Nielsen. Quick thoughts on research. Michael Nielsen's notebook, 2023. URL https://michaelnotebook.com/qtr/index.html. Essay / talk.

[5] Chris Olah and Shan Carter. Research Debt. Distill, 2017. URL https://distill.pub/2017/research-debt/. Essay / talk.

[6] Michael Nielsen and Kanjun Qiu. A Vision of Metascience: An Engine of Improvement for the Social Processes of Science. Science++, 2022. URL https://scienceplusplus.org/metascience/index.html. Essay / talk.

[7] Jingqi Tong, Mingzhe Li, Hangcheng Li, Yongzhuo Yang, Yurong Mou, Weijie Ma, et al. AI Can Learn Scientific Taste. arXiv, 2026. URL https://arxiv.org/abs/2603.14473. Preprint / technical report.

[8] Bo Jiang. HindSight: Evaluating LLM-Generated Research Ideas via Future Impact. arXiv, 2026. URL https://arxiv.org/abs/2603.15164. Preprint / technical report.

[9] Oliver Jaffe and Dane Sherburn. TasteVal: Measuring the Experimental Research Taste of AI Systems Against Human Experts. arXiv, 2026. URL https://arxiv.org/abs/2610.06824. Preprint / technical report.

[10] Chenglei Si, Tatsunori Hashimoto, and Diyi Yang. The Ideation-Execution Gap: Execution Outcomes of LLM-Generated versus Human Research Ideas. ICLR 2026, 2026. URL https://arxiv.org/abs/2506.20803. First public release: 2025.

[11] Tim Schopf and Michael Färber. Is This Idea Novel? An Automated Benchmark for Judgment of Research Ideas. LREC 2026, 2026. URL https://aclanthology.org/2026.lrec-1.370/.

[12] Ming Zhang, Kexin Tan, Yueyuan Huang, Yujiong Shen, Chunchun Ma, Li Ju, et al. OpenNovelty: An LLM-powered Agentic System for Verifiable Scholarly Novelty Assessment. arXiv, 2026. URL https://arxiv.org/abs/2601.01576. Preprint / technical report.

[13] Shuofei Qiao, Yunxiang Wei, Xuehai Wang, Bin Wu, Boyang Xue, Ningyu Zhang, et al. InnoEval: On Research Idea Evaluation as a Knowledge-Grounded, Multi-Perspective Reasoning Problem. ICML 2026, 2026. URL https://arxiv.org/abs/2602.14367.

[14] Fengxian Ji, Yuke Li, Jingpu Yang, Juanfan Wu, Fan Zhang, Zhexuan Cui, et al. Style Wins, Substance Loses: A Diagnosis of LLM-as-Judge in Idea Generation. arXiv, 2026. URL https://arxiv.org/abs/2608.01666. Preprint / technical report.

[15] Qingyun Wang, Doug Downey, Heng Ji, and Tom Hope. SciMON: Scientific Inspiration Machines Optimized for Novelty. ACL 2024, 2024. URL https://aclanthology.org/2024.acl-long.18/. First public release: 2023.

[16] Jinheon Baek, Sujay Kumar Jauhar, Silviu Cucerzan, and Sung Ju Hwang. ResearchAgent: Iterative Research Idea Generation over Scientific Literature with Large Language Models. NAACL 2025, 2025. URL https://aclanthology.org/2025.naacl-long.342/. First public release: 2024.

[17] Wenxiao Wang, Lihui Gu, Liye Zhang, Yunxiang Luo, Yi Dai, Chen Shen, et al. SciPIP: An LLM-based Scientific Paper Idea Proposer. arXiv, 2024. URL https://arxiv.org/abs/2410.23166. Preprint / technical report.

[18] Long Li, Weiwen Xu, Jiayan Guo, Ruochen Zhao, Xingxuan Li, Yuqian Yuan, et al. Chain of Ideas: Revolutionizing Research Via Novel Idea Development with LLM Agents. Findings of EMNLP 2025, 2025. URL https://aclanthology.org/2025.findings-emnlp.477/. First public release: 2024.

[19] Zonglin Yang, Xinya Du, Junxian Li, Jie Zheng, Soujanya Poria, and Erik Cambria. Large Language Models for Automated Open-domain Scientific Hypotheses Discovery. Findings of ACL 2024, 2024. URL https://aclanthology.org/2024.findings-acl.804/. First public release: 2023.

[20] Alireza Ghafarollahi and Markus J. Buehler. SciAgents: Automating Scientific Discovery Through Bioinspired Multi-Agent Intelligent Graph Reasoning. Advanced Materials 2025, 2025. URL https://doi.org/10.1002/adma.202413523. First public release: 2024.

[21] Yangqiaoyu Zhou, Haokun Liu, Tejes Srivastava, Hongyuan Mei, and Chenhao Tan. Hypothesis Generation with Large Language Models. NLP4Science 2024, 2024. URL https://aclanthology.org/2024.nlp4science-1.10/.

[22] Haokun Liu, Yangqiaoyu Zhou, Mingxuan Li, Chenfei Yuan, and Chenhao Tan. Literature Meets Data: A Synergistic Approach to Hypothesis Generation. ACL 2025, 2025. URL https://aclanthology.org/2025.acl-long.12/. First public release: 2024.

[23] Marissa Radensky, Simra Shahid, Raymond Fok, Pao Siangliulue, Tom Hope, and Daniel S. Weld. Scideator: Human-LLM Compound System for Scientific Ideation through Facet Recombination and Novelty Evaluation. ACM CAIS 2026, 2026. URL https://arxiv.org/abs/2409.14634. First public release: 2024.

[24] Kevin Pu, K. J. Kevin Feng, Tovi Grossman, Tom Hope, Bhavana Dalvi Mishra, Matt Latzke, et al. IdeaSynth: Iterative Research Idea Development Through Evolving and Composing Idea Facets with Literature-Grounded Feedback. CHI 2025, 2025. URL https://arxiv.org/abs/2410.04025. First public release: 2024.

[25] Yiren Liu, Si Chen, Haocong Cheng, Mengxia Yu, Xiao Ran, Andrew Mo, et al. CoQuest: Exploring Research Question Co-Creation with an LLM-based Agent. CHI 2024, 2024. URL https://arxiv.org/abs/2310.06155. First public release: 2023.

[26] Sikun Guo, Amir Hassan Shariatmadari, Guangzhi Xiong, Albert Huang, Eric Xie, Stefan Bekiranov, et al. IdeaBench: Benchmarking Large Language Models for Research Idea Generation. arXiv, 2024. URL https://arxiv.org/abs/2411.02429. Preprint / technical report.

[27] Kai Ruan, Xuan Wang, Jixiang Hong, Peng Wang, Yang Liu, and Hao Sun. Evaluating LLMs' divergent thinking capabilities for scientific idea generation with minimal context. Nature Communications 2026, 2026. URL https://www.nature.com/articles/s41467-026-70245-1. First public release: 2024.

[28] Chenglei Si, Diyi Yang, and Tatsunori Hashimoto. Can LLMs Generate Novel Research Ideas? A Large-Scale Human Study with 100+ NLP Researchers. ICLR 2025, 2025. URL https://arxiv.org/abs/2409.04109. First public release: 2024.

[29] Andrej Karpathy. autoresearch. Open-source project, 2026. URL https://github.com/karpathy/autoresearch. Software project.

[30] Zhengyao Jiang, Dominik Schmidt, Dhruv Srikanth, Dixing Xu, Ian Kaplan, Deniss Jacenko, et al. AIDE: AI-Driven Exploration in the Space of Code. arXiv, 2025. URL https://arxiv.org/abs/2502.13138. Preprint / technical report.

[31] Xu Yang, Xiao Yang, Shikai Fang, Yifei Zhang, Jian Wang, Bowen Xian, et al. R&D-Agent: An LLM-Agent Framework Towards Autonomous Data Science. arXiv, 2025. URL https://arxiv.org/abs/2505.14738. Preprint / technical report.

[32] Jiajie Jin, Yuyang Hu, Kai Qiu, Qi Dai, Chong Luo, Guanting Dong, et al. Toward Generalist Autonomous Research via Hypothesis-Tree Refinement. arXiv, 2026. URL https://arxiv.org/abs/2606.11926. Preprint / technical report.

[33] Sebastian Musslick, Benjamin Andrew, Chad C. Williams, Joshua T. s. Hewson, Sida Li, Ioana Marinescu, et al. AutoRA: Automated Research Assistant for Closed-Loop Empirical Research. Journal of Open Source Software 2024, 2024. URL https://joss.theoj.org/papers/10.21105/joss.06839.

[34] Adam Foster, Desi R Ivanova, Ilyas Malik, and Tom Rainforth. Deep Adaptive Design: Amortizing Sequential Bayesian Experimental Design. ICML 2021, 2021. URL https://proceedings.mlr.press/v139/foster21a.html.

[35] Patrick Tser Jern Kon, Jiachen Liu, Qiuyi Ding, Yiming Qiu, Zhenning Yang, Yibo Huang, et al. Curie: Toward Rigorous and Automated Scientific Experimentation with AI Agents. arXiv, 2025. URL https://arxiv.org/abs/2502.16069. Preprint / technical report.

[36] Kexin Huang, Ying Jin, Ryan Li, Michael Y. Li, Emmanuel Candes, and Jure Leskovec. Automated Hypothesis Validation with Agentic Sequential Falsifications. ICML 2025, 2025. URL https://proceedings.mlr.press/v267/huang25n.html.

[37] Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov, Matej Balog, M. Pawan Kumar, Emilien Dupont, et al. Mathematical discoveries from program search with large language models. Nature 2023, 2023. URL https://www.nature.com/articles/s41586-023-06924-6.

[38] Alexander Novikov, Ngân Vũ, Marvin Eisenberger, Emilien Dupont, Po-Sen Huang, Adam Zsolt Wagner, et al. AlphaEvolve: A coding agent for scientific and algorithmic discovery. arXiv / technical report, 2025. URL https://arxiv.org/abs/2506.13131. Preprint / technical report.

[39] Tony Feng, Trieu H. Trinh, Garrett Bingham, Dawsen Hwang, Yuri Chervonyi, Junehyuk Jung, et al. Towards Autonomous Mathematics Research. arXiv, 2026. URL https://arxiv.org/abs/2602.10177. Preprint / technical report.

[40] Chris Lu, Cong Lu, Robert Tjarko Lange, Jakob Foerster, Jeff Clune, and David Ha. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery. arXiv, 2024. URL https://arxiv.org/abs/2408.06292. Preprint / technical report.

[41] Yutaro Yamada, Robert Tjarko Lange, Cong Lu, Shengran Hu, Chris Lu, Jakob Foerster, et al. The AI Scientist-v2: Workshop-Level Automated Scientific Discovery via Agentic Tree Search. arXiv, 2025. URL https://arxiv.org/abs/2504.08066. Preprint / technical report.

[42] Jiabin Tang, Lianghao Xia, Zhonghang Li, and Chao Huang. AI-Researcher: Autonomous Scientific Innovation. NeurIPS 2025, 2025. URL https://arxiv.org/abs/2505.18705.

[43] Samuel Schmidgall, Yusheng Su, Ze Wang, Ximeng Sun, Jialian Wu, Xiaodong Yu, et al. Agent Laboratory: Using LLM Agents as Research Assistants. Findings of EMNLP 2025, 2025. URL https://aclanthology.org/2025.findings-emnlp.320/.

[44] Juraj Gottweis, Wei-Hung Weng, Alexander Daryin, Tao Tu, Petar Sirkovic, Artiom Myaskovsky, et al. Accelerating scientific discovery with Co-Scientist. Nature 2026, 2026. URL https://www.nature.com/articles/s41586-026-10644-y. First public release: 2025.

[45] Ludovico Mitchener, Angela Yiu, Benjamin Chang, Mathieu Bourdenx, Tyler Nadolski, Arvis Sulovari, et al. Kosmos: An AI Scientist for Autonomous Discovery. arXiv, 2025. URL https://arxiv.org/abs/2511.02824. Preprint / technical report.

[46] Samuel Schmidgall and Michael Moor. AgentRxiv: Towards Collaborative Autonomous Research. arXiv, 2025. URL https://arxiv.org/abs/2503.18102. Preprint / technical report.

[47] Yifan Zhang, Yunheng Zou, Shaokun Zhang, Jian Hu, Hao Zhang, Binfeng Xu, et al. Agora: Git as Shared Memory for Collective AutoResearch. arXiv, 2026. URL https://arxiv.org/abs/2609.18094. Preprint / technical report.

[48] Yougang Lyu, Xi Zhang, Yuyue Zhao, Konstantinos Papakostas, Xinhao Yi, Shuyu Guo, et al. EvoScientist: Towards Multi-Agent Evolving AI Scientists for End-to-End Scientific Discovery. arXiv, 2026. URL https://arxiv.org/abs/2603.08127. Preprint / technical report.

[49] Shiyang Feng, Runmin Ma, Xiangchao Yan, Yue Fan, Yusong Hu, Songtao Huang, et al. InternAgent-1.5: A Unified Agentic Framework for Long-Horizon Autonomous Scientific Discovery. arXiv, 2026. URL https://arxiv.org/abs/2602.08990. Preprint / technical report.

[50] Jiaqi Liu, Shi Qiu, Mairui Li, Bingzhou Li, Haonian Ji, Siwei Han, et al. AutoResearchClaw: Self-Reinforcing Autonomous Research with Human-AI Collaboration. arXiv, 2026. URL https://arxiv.org/abs/2605.20025. Preprint / technical report.

[51] Ziqing Qian, Jiaying Lei, Yifang Wang, and Nan Cao. HypoForge: A Self-Improving Multi-Agent Framework for Automated Hypothesis Generation and Testing via Scientific Skill Learning. arXiv, 2026. URL https://arxiv.org/abs/2608.25770. Preprint / technical report.

[52] Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language Agents with Verbal Reinforcement Learning. NeurIPS 2023, 2023. URL https://arxiv.org/abs/2303.11366.

[53] Jiakang Yuan, Xiangchao Yan, Bo Zhang, Tao Chen, Botian Shi, Wanli Ouyang, et al. Dolphin: Moving Towards Closed-loop Auto-research through Thinking, Practice, and Feedback. ACL 2025, 2025. URL https://aclanthology.org/2025.acl-long.1056/.

[54] Qi Liu, Ruochen Hao, Can Li, and Wanjing Ma. OR-Agent: Bridging Evolutionary Search and Structured Research for Automated Heuristic Design. arXiv, 2026. URL https://arxiv.org/abs/2602.13769. Preprint / technical report.

[55] Shengran Hu, Cong Lu, and Jeff Clune. Automated Design of Agentic Systems. ICLR 2025, 2025. URL https://arxiv.org/abs/2408.08435. First public release: 2024.

[56] Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, and Jeff Clune. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents. ICLR 2026, 2026. URL https://arxiv.org/abs/2505.22954. First public release: 2025.

[57] Yaonan Qu and Meng Lu. Bilevel Autoresearch: Meta-Autoresearching Itself. arXiv, 2026. URL https://arxiv.org/abs/2603.23420. Preprint / technical report.

[58] Yixuan Weng, Minjun Zhu, Guangsheng Bao, Hongbo Zhang, Jindong Wang, Yue Zhang, et al. CycleResearcher: Improving Automated Research via Automated Review. ICLR 2025, 2025. URL https://arxiv.org/abs/2411.00816. First public release: 2024.

[59] Xuchen Gong, Shane Gu, Haokun Liu, Dixi Yao, Chenhao Tan, and Tian Li. Learning Scientific Exploration from Human Research Decision Trajectories. arXiv, 2026. URL https://arxiv.org/abs/2610.07184. Preprint / technical report.

[60] James Mooney, Zae Myung Kim, Young-Jun Lee, and Dongyeop Kang. Structure Liberates: How Constrained Sensemaking Produces More Novel Research Output. arXiv, 2026. URL https://arxiv.org/abs/2605.00557. Preprint / technical report.

[61] Yunxiang Zhang, Kang Zhou, Zhichao Xu, Kiran Ramnath, Yun Zhou, Sangmin Woo, et al. Learning to Ideate for Machine Learning Engineering Agents. EACL 2026 (Short Papers), 2026. URL https://aclanthology.org/2026.eacl-short.32/.

[62] Mert Yuksekgonul, Daniel Koceja, Xinhao Li, Federico Bianchi, Jed Mccaleb, Xiaolong Wang, et al. Learning to Discover at Test Time. ICML 2026, 2026. URL https://proceedings.mlr.press/v306/yuksekgonul26a.html.

[63] Young-Jun Lee, Seungone Kim, Minki Kang, Alistair Cheong Liang Chuen, Zerui Chen, Seungho Han, et al. Evolution Fine-Tuning: Learning to Discover Across 371 Optimization Tasks. NeurIPS 2026 (accepted), 2026. URL https://arxiv.org/abs/2606.29082. Preprint / technical report.

[64] Qian Huang, Jian Vora, Percy Liang, and Jure Leskovec. MLAgentBench: Evaluating Language Agents on Machine Learning Experimentation. ICML 2024, 2024. URL https://arxiv.org/abs/2310.03302. First public release: 2023.

[65] Jun Shern Chan, Neil Chowdhury, Oliver Jaffe, James Aung, Dane Sherburn, Evan Mays, et al. MLE-bench: Evaluating Machine Learning Agents on Machine Learning Engineering. ICLR 2025, 2025. URL https://arxiv.org/abs/2410.07095. First public release: 2024.

[66] Deepak Nathani, Lovish Madaan, Nicholas Roberts, Nikolay Bashlykov, Ajay Menon, Vincent Moens, et al. MLGym: A New Framework and Benchmark for Advancing AI Research Agents. COLM 2025, 2025. URL https://arxiv.org/abs/2502.14499.

[67] Alisia Lupidi, Bhavul Gauri, Thomas Simon Foster, Bassel Al Omari, Despoina Magka, Alberto Pepe, et al. AIRS-Bench: a Suite of Tasks for Frontier AI Research Science Agents. arXiv, 2026. URL https://arxiv.org/abs/2602.06855. Preprint / technical report.

[68] Hjalmar Wijk, Tao Lin, Joel Becker, Sami Jawhar, Neev Parikh, Thomas Broadley, et al. RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts. ICML 2025, 2025. URL https://arxiv.org/abs/2411.15114. First public release: 2024.

[69] Qiran Zou, Hou Hei Lam, Wenhao Zhao, Tingting Chen, Yiming Tang, Samson Yu, et al. FML-bench: A Controlled Study of AI Research Agent Strategies from the Perspective of Search Dynamics. arXiv, 2026. URL https://arxiv.org/abs/2605.17373. Preprint / technical report.

[70] Zachary S. Siegel, Sayash Kapoor, Nitya Nadgir, Benedikt Stroebl, and Arvind Narayanan. CORE-Bench: Fostering the Credibility of Published Research Through a Computational Reproducibility Agent Benchmark. TMLR 2025, 2025. URL https://arxiv.org/abs/2409.11363. First public release: 2024.

[71] Giulio Starace, Oliver Jaffe, Dane Sherburn, James Aung, Jun Shern Chan, Leon Maksin, et al. PaperBench: Evaluating AI's Ability to Replicate AI Research. ICML 2025, 2025. URL https://arxiv.org/abs/2504.01848.

[72] Ziru Chen, Shijie Chen, Yuting Ning, Qianheng Zhang, Boshi Wang, Botao Yu, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery. ICLR 2025, 2025. URL https://arxiv.org/abs/2410.05080. First public release: 2024.

[73] Minyang Tian, Luyu Gao, Shizhuo Dylan Zhang, Xinan Chen, Cunwei Fan, Xuefei Guo, et al. SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks, 2024. URL https://arxiv.org/abs/2407.13168.

[74] Bodhisattwa Prasad Majumder, Harshit Surana, Dhruv Agarwal, Bhavana Dalvi Mishra, Abhijeetsingh Meena, Aryan Prakhar, et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. ICLR 2025, 2025. URL https://arxiv.org/abs/2407.01725. First public release: 2024.

[75] Ruoyao Wang, Peter Jansen, Marc-Alexandre Côté, and Prithviraj Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? EMNLP 2022, 2022. URL https://aclanthology.org/2022.emnlp-main.775/.

[76] Peter Jansen, Marc-Alexandre Côté, Tushar Khot, Erin Bransom, Bhavana Dalvi Mishra, Bodhisattwa Prasad Majumder, et al. DISCOVERYWORLD: A Virtual Environment for Developing and Evaluating Automated Scientific Discovery Agents. NeurIPS 2024 Datasets and Benchmarks, 2024. URL https://arxiv.org/abs/2406.06769.

[77] Elliot Glazer, Ege Erdil, Tamay Besiroglu, Diego Chicharro, Evan Chen, Alex Gunning, et al. FrontierMath: A Benchmark for Evaluating Advanced Mathematical Reasoning in AI. arXiv, 2024. URL https://arxiv.org/abs/2411.04872. Preprint / technical report.

[78] Hui Chen, Miao Xiong, Yujie Lu, Wei Han, Ailin Deng, Yufei He, et al. MLR-Bench: Evaluating AI Agents on Open-Ended Machine Learning Research. NeurIPS 2025 Datasets and Benchmarks, 2025. URL https://arxiv.org/abs/2505.19955.

[79] Martin Bertran, Riccardo Fogliato, and Zhiwei Steven Wu. Many AI analysts, one dataset: Navigating the agentic data science multiverse. PNAS 2026, 2026. URL https://www.pnas.org/doi/10.1073/pnas.2606495123.